# Laboratorio 8

2026-04-26

## Contents


Preparacion del entorno analitico . . . 2
Carga y diagnostico inicial del conjunto de datos . . . 2
Reutilizacion del particionamiento experimental . . . 4
Diagnostico inicial de predictores . . . 7
Transformaciones para modelado SVM . . . 12
Cierre del avance . . . 14
Diseno experimental de los modelos SVM . . . 14
Evaluacion de kernels para clasificacion de precios . . . 16
- Kernel lineal . . . 16
- Kernel radial . . . 18
- Kernel polinomial . . . 19

Prediccion de categorias de precio . . . 20
Primer analisis comparativo de desempeno . . . 21
Evaluacion de la clasificacion en el conjunto de prueba . . . 23
Analisis de errores por categoria de precio . . . 25
Diagnostico de generalizacion de los modelos SVM . . . 27
Implicaciones del ajuste para la toma de decisiones de SmartStay Advisors . . . 28
Recomendaciones para mejorar el desempeno predictivo . . . 28
Contraste de desempeno entre configuraciones SVM . . . 29
Lectura operativa de los errores de clasificacion . . . 30
Implicaciones para la categorizacion de precios . . . 33
Seleccion del clasificador SVM mas estable . . . 34
Redaccion integrable al informe ejecutivo . . . 35
Preparacion del problema de prediccion de precios . . . 35
Transformacion de predictores para SVR . . . 35
Ajuste de modelos de regresion con vectores de soporte . . . 37
- SVR con kernel lineal . . . 37
- SVR con kernel radial . . . 37

SVR con kernel polinomial . . . . . 37
Evaluacion del error predictivo . . . . . 38
Diagnostico visual de predicciones . . . . . 38
Comparacion con modelos de regresion anteriores . . . . . 40

## Preparacion del entorno analitico

```
paquetes_requeridos <- c("tidyverse", "caret", "e1071", "kernlab", "knitr")
paquetes_opcionales <- c("MLmetrics")

for (pkg in paquetes_requeridos) {
  if (!requireNamespace(pkg, quietly = TRUE)) {
    stop(paste("Falta instalar el paquete requerido:", pkg))
  }
  suppressPackageStartupMessages(library(pkg, character.only = TRUE))
}

for (pkg in paquetes_opcionales) {
  if (requireNamespace(pkg, quietly = TRUE)) {
    suppressPackageStartupMessages(library(pkg, character.only = TRUE))
  } else {
    message("Paquete opcional no disponible en este entorno: ", pkg)
  }
}

set.seed(123)
```

Este documento prepara los datos para clasificacion con SVM sobre la variable objetivo categorica de precio. Se prioriza reproducibilidad, limpieza del flujo y trazabilidad del particionamiento experimental.

## Carga y diagnostico inicial del conjunto de datos

```
objetos_cargados <- load("listings.RData")

if ("listings" %in% objetos_cargados) {
  datos <- get("listings")
} else {
  candidatos_df <- objetos_cargados[sapply(objetos_cargados, function(x) is.data.frame(get(x)))]
  if (length(candidatos_df) == 0) {
    stop("No se encontro ningun data frame en listings.RData")
  }
  datos <- get(candidatos_df[1])
}

datos <- as.data.frame(datos)
```

```
cat("Objeto usado:", if ("listings" %in% objetos_cargados) "listings" else "primer data.frame encontrado
```

```
## Objeto usado: listings
```

```r
cat("Dimensiones:", nrow(datos), "filas x", ncol(datos), "columnas\n")
```

```
## Dimensiones: 171748 filas x 80 columnas
```

```r
resumen_tipos <- tibble(
  variable = names(datos),
  clase = sapply(datos, function(x) paste(class(x), collapse = ", ")),
  n_unicos = sapply(datos, function(x) dplyr::n_distinct(x, na.rm = TRUE)),
  na_count = sapply(datos, function(x) sum(is.na(x))),
  na_pct = round(100 * na_count / nrow(datos), 2)
)

resumen_tipos %>%
  count(clase, sort = TRUE) %>%
  kable(caption = "Cantidad de variables por tipo")
```

Table 1: Cantidad de variables por tipo

| clase | n |
|---|---|
| character | 37 |
| integer | 27 |
| numeric | 15 |
| logical | 1 |

```r
resumen_tipos %>%
  arrange(desc(na_count)) %>%
  slice_head(n = 20) %>%
  kable(caption = "Top 20 variables con mas valores faltantes")
```

Table 2: Top 20 variables con mas valores faltantes

| variable | clase | n_unicos | na_count | na_pct |
|---|---|---|---|---|
| calendar_updated | logical | 0 | 171748 | 100.00 |
| estimated_revenue_l365d | integer | 9746 | 95502 | 55.61 |
| price | character | 2321 | 89381 | 52.04 |
| neighbourhood_group_cleansed | character | 17 | 50683 | 29.51 |
| review_scores_location | numeric | 184 | 40328 | 23.48 |
| review_scores_value | numeric | 187 | 40328 | 23.48 |
| review_scores_checkin | numeric | 152 | 40324 | 23.48 |
| review_scores_accuracy | numeric | 171 | 40312 | 23.47 |
| review_scores_communication | numeric | 161 | 40308 | 23.47 |
| review_scores_cleanliness | numeric | 195 | 40302 | 23.47 |
| review_scores_rating | numeric | 176 | 40287 | 23.46 |
| reviews_per_month | numeric | 1236 | 40287 | 23.46 |
| beds | integer | 40 | 31686 | 18.45 |
| bathrooms | numeric | 38 | 31396 | 18.28 |
| license | character | 52058 | 10533 | 6.13 |

| variable | clase | n_unicos | na_count | na_pct |
|---|---|---|---|---|
| bedrooms | integer | 23 | 10473 | 6.10 |
| host_listings_count | integer | 394 | 876 | 0.51 |
| host_total_listings_count | integer | 481 | 876 | 0.51 |
| minimum_minimum_nights | integer | 185 | 71 | 0.04 |
| maximum_minimum_nights | integer | 211 | 71 | 0.04 |

```r
if ("price" %in% names(datos) && is.character(datos$price)) {
  datos <- datos %>% mutate(price = readr::parse_number(price))
}

if (!"price" %in% names(datos)) {
  stop("No existe la variable 'price' en el conjunto de datos.")
}
```

En esta base, la variable `price` se encuentra como texto con simbolos monetarios y se convierte a formato numerico para poder construir la variable objetivo y evitar problemas en modelado.

## Reutilizacion del particionamiento experimental

```r
detectar_particion_previa <- function(datos_base) {
  resultado <- list(
    encontrada = FALSE,
    fuente = NA_character_,
    train = NULL,
    test = NULL,
    train_index = NULL
  )

  # Caso 1: objetos train/test ya presentes en el ambiente.
  if (exists("train", inherits = FALSE) && exists("test", inherits = FALSE)) {
    tr <- get("train")
    te <- get("test")
    if (is.data.frame(tr) && is.data.frame(te)) {
      resultado$encontrada <- TRUE
      resultado$fuente <- "objetos train/test ya presentes en el ambiente"
      resultado$train <- tr
      resultado$test <- te
      return(resultado)
    }
  }

  # Caso 2: archivos comunes de particion.
  candidatos <- list.files(
    path = ".",
    recursive = TRUE,
    full.names = TRUE,
    pattern = "(?i)(train|test|split|particion|partition).*(\\.rds|\\.rda|\\.RData)$"
  )
```

```r
if (length(candidatos) == 0) {
  return(resultado)
}

for (archivo in candidatos) {
  ext <- tolower(tools::file_ext(archivo))

  if (ext == "rds") {
    obj <- tryCatch(readRDS(archivo), error = function(e) NULL)
    if (is.null(obj)) next

    # Formato lista con train/test.
    if (is.list(obj) && all(c("train", "test") %in% names(obj))) {
      if (is.data.frame(obj$train) && is.data.frame(obj$test)) {
        resultado$encontrada <- TRUE
        resultado$fuente <- paste("archivo", archivo, "(lista train/test)")
        resultado$train <- obj$train
        resultado$test <- obj$test
        return(resultado)
      }
    }

    # Formato lista con indice.
    if (is.list(obj) && "train_index" %in% names(obj)) {
      idx <- obj$train_index
      if (is.numeric(idx) && all(idx >= 1) && all(idx <= nrow(datos_base))) {
        resultado$encontrada <- TRUE
        resultado$fuente <- paste("archivo", archivo, "(indice train)")
        resultado$train_index <- idx
        resultado$train <- datos_base[idx, , drop = FALSE]
        resultado$test <- datos_base[-idx, , drop = FALSE]
        return(resultado)
      }
    }
  }

  if (ext %in% c("rda", "rdata")) {
    env_tmp <- new.env(parent = emptyenv())
    cargados <- tryCatch(load(archivo, envir = env_tmp), error = function(e) character(0))
    if (length(cargados) == 0) next

    if (all(c("train", "test") %in% ls(env_tmp))) {
      tr <- get("train", envir = env_tmp)
      te <- get("test", envir = env_tmp)
      if (is.data.frame(tr) && is.data.frame(te)) {
        resultado$encontrada <- TRUE
        resultado$fuente <- paste("archivo", archivo, "(objetos train/test)")
        resultado$train <- tr
        resultado$test <- te
        return(resultado)
      }
    }
  }
```

```r
  }

  resultado
}

if (!"price_category" %in% names(datos)) {
  q1 <- quantile(datos$price, 1 / 3, na.rm = TRUE)
  q2 <- quantile(datos$price, 2 / 3, na.rm = TRUE)

  datos <- datos %>%
    mutate(
      price_category = case_when(
        price <= q1 ~ "barata",
        price <= q2 ~ "media",
        TRUE ~ "cara"
      ),
      price_category = factor(price_category, levels = c("barata", "media", "cara"))
    )
} else {
  datos <- datos %>%
    mutate(price_category = as.factor(price_category))
}

particion_previa <- detectar_particion_previa(datos)

if (isTRUE(particion_previa$encontrada)) {
  train <- particion_previa$train
  test <- particion_previa$test
  fuente_particion <- particion_previa$fuente
} else {
  set.seed(123)
  indice_train <- createDataPartition(datos$price_category, p = 0.8, list = FALSE)

  train <- datos[indice_train, , drop = FALSE]
  test <- datos[-indice_train, , drop = FALSE]

  fuente_particion <- "reconstruida con set.seed(123) y createDataPartition()"

  dir.create("artefactos", showWarnings = FALSE)
  saveRDS(list(train_index = indice_train), file = "artefactos/particion_train_idx.rds")
}

cat("Fuente de particionamiento:", fuente_particion, "\n")
```

```
## Fuente de particionamiento: archivo ./artefactos/particion_train_idx.rds (indice train)
```

```r
cat("Dimensiones train:", paste(dim(train), collapse = " x "), "\n")
```

```
## Dimensiones train: 137400 x 81
```

```r
cat("Dimensiones test :", paste(dim(test), collapse = " x "), "\n")
```

```
## Dimensiones test : 34348 x 81
```

```r
prop_train <- prop.table(table(train$price_category))
prop_test <- prop.table(table(test$price_category))

tabla_props <- bind_rows(
  tibble(conjunto = "train", categoria = names(prop_train), proporcion = as.numeric(prop_train)),
  tibble(conjunto = "test", categoria = names(prop_test), proporcion = as.numeric(prop_test))
)

tabla_props %>%
  pivot_wider(names_from = conjunto, values_from = proporcion) %>%
  mutate(diferencia_abs = abs(train - test)) %>%
  kable(digits = 4, caption = "Comparacion de proporciones por categoria de precio")
```

Table 3: Comparacion de proporciones por categoria de precio

| categoria | train | test | diferencia_abs |
|---|---|---|---|
| barata | 0.1496 | 0.1496 | 0 |
| media | 0.1465 | 0.1464 | 0 |
| cara | 0.7040 | 0.7040 | 0 |

Las proporciones por categoria entre entrenamiento y prueba se mantienen comparables, lo cual permite contrastar modelos futuros bajo condiciones experimentales consistentes.

## Diagnostico inicial de predictores

```r
glimpse(train)
```

```
## Rows: 137,400
## Columns: 81
## $ id                                          <dbl> 6448, 8502, 22828, 47572,~
## $ listing_url                                 <chr> "https://www.airbnb.com/r~
## $ scrape_id                                   <dbl> 2.025092e+13, 2.025092e+1~
## $ last_scraped                                <chr> "2025-09-17", "2025-09-17~
## $ source                                      <chr> "city scrape", "city scra~
## $ name                                        <chr> "Secluded Studio @ Zilker~
## $ description                                 <chr> "Clean, private space wit~
## $ neighborhood_overview                       <chr> "The neighborhood is fun ~
## $ picture_url                                 <chr> "https://a0.muscache.com/~
## $ host_id                                     <int> 14156, 25298, 56488, 2159~
## $ host_url                                    <chr> "https://www.airbnb.com/u~
## $ host_name                                   <chr> "Amy", "Karen", "David", ~
## $ host_since                                  <chr> "2009-04-20", "2009-07-11~
## $ host_location                               <chr> "Austin, TX", "Austin, TX~
## $ host_about                                  <chr> "We are a family of four ~
## $ host_response_time                          <chr> "within an hour", "within~
## $ host_response_rate                          <chr> "100%", "100%", "100%", "~
## $ host_acceptance_rate                        <chr> "96%", "60%", "71%", "N/A~
```

```
## $ host_is_superhost                          <chr> "t", "f", "t", "f", "f", ~
## $ host_thumbnail_url                         <chr> "https://a0.muscache.com/~
## $ host_picture_url                           <chr> "https://a0.muscache.com/~
## $ host_neighbourhood                         <chr> "Zilker", "East Riverside~
## $ host_listings_count                        <int> 1, 1, 1, 1, 1, 1, 1, 1, 2~
## $ host_total_listings_count                  <int> 2, 1, 1, 1, 2, 2, 2, 1, 5~
## $ host_verifications                         <chr> "['email', 'phone']", "['~
## $ host_has_profile_pic                       <chr> "t", "t", "t", "t", "t", ~
## $ host_identity_verified                     <chr> "t", "f", "t", "t", "f", ~
## $ neighbourhood                              <chr> "Neighborhood highlights"~
## $ neighbourhood_cleansed                     <chr> "78704", "78741", "78741"~
## $ neighbourhood_group_cleansed               <chr> NA, NA, NA, NA, NA, NA, N~
## $ latitude                                   <dbl> 30.26034, 30.23466, 30.23~
## $ longitude                                  <dbl> -97.76487, -97.73682, -97~
## $ property_type                              <chr> "Entire guesthouse", "Ent~
## $ room_type                                  <chr> "Entire home/apt", "Entir~
## $ accommodates                               <int> 2, 2, 2, 1, 2, 6, 3, 2, 2~
## $ bathrooms                                  <dbl> 1.0, 1.0, 1.0, 1.0, 1.0, ~
## $ bathrooms_text                             <chr> "1 bath", "1 bath", "1 ba~
## $ bedrooms                                   <int> 1, 1, 1, 1, 2, 1, 1, 1, 1~
## $ beds                                       <int> 2, 1, 1, 1, 0, 3, 1, 1, 1~
## $ amenities                                  <chr> "[\"Private patio or balc~
## $ price                                      <dbl> 160, 38, 58, 49, 300, 150~
## $ minimum_nights                             <int> 3, 4, 30, 30, 7, 1, 2, 3,~
## $ maximum_nights                             <int> 365, 90, 365, 120, 365, 3~
## $ minimum_minimum_nights                     <int> 3, 3, 30, 30, 7, 1, 2, 3,~
## $ maximum_minimum_nights                     <int> 3, 14, 30, 30, 7, 5, 2, 3~
## $ minimum_maximum_nights                     <int> 1125, 90, 365, 120, 365, ~
## $ maximum_maximum_nights                     <int> 1125, 90, 365, 120, 365, ~
## $ minimum_nights_avg_ntm                     <dbl> 3.0, 6.0, 30.0, 30.0, 7.0~
## $ maximum_nights_avg_ntm                     <dbl> 1125.0, 90.0, 365.0, 120.~
## $ calendar_updated                           <lgl> NA, NA, NA, NA, NA, NA, N~
## $ has_availability                           <chr> "t", "t", "t", "t", "t", ~
## $ availability_30                            <int> 12, 29, 27, 0, 30, 8, 18,~
## $ availability_60                            <int> 30, 59, 40, 0, 60, 38, 46~
## $ availability_90                            <int> 50, 88, 40, 0, 90, 68, 75~
## $ availability_365                           <int> 316, 88, 211, 258, 365, 3~
## $ calendar_last_scraped                      <chr> "2025-09-17", "2025-09-17~
## $ number_of_reviews                          <int> 339, 54, 56, 9, 2, 1090, ~
## $ number_of_reviews_ltm                      <int> 14, 1, 3, 0, 0, 26, 2, 0,~
## $ number_of_reviews_l30d                     <int> 1, 0, 0, 0, 0, 0, 0, 0, 0~
## $ availability_eoy                           <int> 61, 88, 40, 0, 106, 84, 7~
## $ number_of_reviews_ly                       <int> 20, 2, 3, 0, 0, 56, 7, 0,~
## $ estimated_occupancy_l365d                  <int> 84, 8, 180, 0, 0, 156, 12~
## $ estimated_revenue_l365d                    <int> 13440, 304, 10440, 0, 0, ~
## $ first_review                               <chr> "2011-09-06", "2010-02-19~
## $ last_review                                <chr> "2025-08-20", "2025-05-05~
## $ review_scores_rating                       <dbl> 4.97, 4.57, 4.95, 5.00, 5~
## $ review_scores_accuracy                     <dbl> 4.97, 4.55, 5.00, 5.00, 5~
## $ review_scores_cleanliness                  <dbl> 4.96, 4.67, 4.98, 5.00, 5~
## $ review_scores_checkin                      <dbl> 4.99, 4.85, 5.00, 5.00, 5~
## $ review_scores_communication                <dbl> 4.98, 4.88, 5.00, 5.00, 5~
## $ review_scores_location                     <dbl> 4.97, 4.69, 4.72, 5.00, 5~
## $ review_scores_value                        <dbl> 4.88, 4.63, 4.84, 5.00, 5~
```

```
## $ license                                       <chr> NA, NA, NA, NA, NA, NA, N~
## $ instant_bookable                              <chr> "t", "f", "f", "f", "f", ~
## $ calculated_host_listings_count                <int> 1, 1, 1, 1, 1, 1, 1, 1, 2~
## $ calculated_host_listings_count_entire_homes   <int> 1, 1, 1, 0, 1, 1, 1, 1, 2~
## $ calculated_host_listings_count_private_rooms  <int> 0, 0, 0, 1, 0, 0, 0, 0, 0~
## $ calculated_host_listings_count_shared_rooms   <int> 0, 0, 0, 0, 0, 0, 0, 0, 0~
## $ reviews_per_month                             <dbl> 1.98, 0.28, 0.30, 0.11, 0~
## $ city                                          <chr> "Austin, Texas", "Austin,~
## $ price_category                                <fct> media, barata, barata, ba~
```

```r
resumen_numericas <- train %>%
  summarise(across(where(is.numeric), list(
    media = ~ mean(.x, na.rm = TRUE),
    sd = ~ sd(.x, na.rm = TRUE),
    min = ~ min(.x, na.rm = TRUE),
    max = ~ max(.x, na.rm = TRUE)
  )))

resumen_na <- train %>%
  summarise(across(everything(), ~ sum(is.na(.x)))) %>%
  pivot_longer(everything(), names_to = "variable", values_to = "na_count") %>%
  mutate(na_pct = 100 * na_count / nrow(train)) %>%
  arrange(desc(na_count))

perfil_categoricas <- train %>%
  select(where(~ is.character(.x) || is.factor(.x))) %>%
  summarise(across(everything(), ~ n_distinct(.x, na.rm = TRUE))) %>%
  pivot_longer(everything(), names_to = "variable", values_to = "n_categorias") %>%
  arrange(desc(n_categorias))

resumen_na %>%
  slice_head(n = 20) %>%
  kable(caption = "Variables con mayor cantidad de NA en entrenamiento")
```

Table 4: Variables con mayor cantidad de NA en entrenamiento

| variable | na_count | na_pct |
|---|---|---|
| calendar_updated | 137400 | 100.0000000 |
| price | 76466 | 55.6521106 |
| estimated_revenue_l365d | 76466 | 55.6521106 |
| neighbourhood_group_cleansed | 40600 | 29.5487627 |
| review_scores_value | 32269 | 23.4854440 |
| review_scores_location | 32268 | 23.4847162 |
| review_scores_checkin | 32265 | 23.4825328 |
| review_scores_accuracy | 32255 | 23.4752547 |
| review_scores_communication | 32251 | 23.4723435 |
| review_scores_cleanliness | 32247 | 23.4694323 |
| review_scores_rating | 32237 | 23.4621543 |
| reviews_per_month | 32237 | 23.4621543 |
| beds | 25356 | 18.4541485 |
| bathrooms | 25120 | 18.2823872 |
| license | 8455 | 6.1535662 |

| variable | na_count | na_pct |
|---|---|---|
| bedrooms | 8342 | 6.0713246 |
| host_listings_count | 701 | 0.5101892 |
| host_total_listings_count | 701 | 0.5101892 |
| minimum_minimum_nights | 54 | 0.0393013 |
| maximum_minimum_nights | 54 | 0.0393013 |

```r
perfil_categoricas %>%
  slice_head(n = 20) %>%
  kable(caption = "Variables categoricas con mayor cardinalidad")
```

Table 5: Variables categoricas con mayor cardinalidad

| variable | n_categorias |
|---|---|
| listing_url | 137400 |
| picture_url | 134531 |
| name | 131353 |
| amenities | 121138 |
| description | 115584 |
| host_url | 66581 |
| host_picture_url | 64441 |
| host_thumbnail_url | 64415 |
| neighborhood_overview | 50122 |
| license | 42592 |
| host_about | 35387 |
| host_name | 19852 |
| host_since | 5929 |
| first_review | 5171 |
| last_review | 3795 |
| host_neighbourhood | 2677 |
| host_location | 2574 |
| neighbourhood_cleansed | 853 |
| property_type | 110 |
| host_acceptance_rate | 103 |

```r
ggplot(train, aes(x = price_category)) +
  geom_bar(fill = "#2E86AB") +
  labs(
    title = "Distribucion de la categoria de precio en entrenamiento",
    x = "Categoria de precio",
    y = "Cantidad de propiedades"
  ) +
  theme_minimal()
```

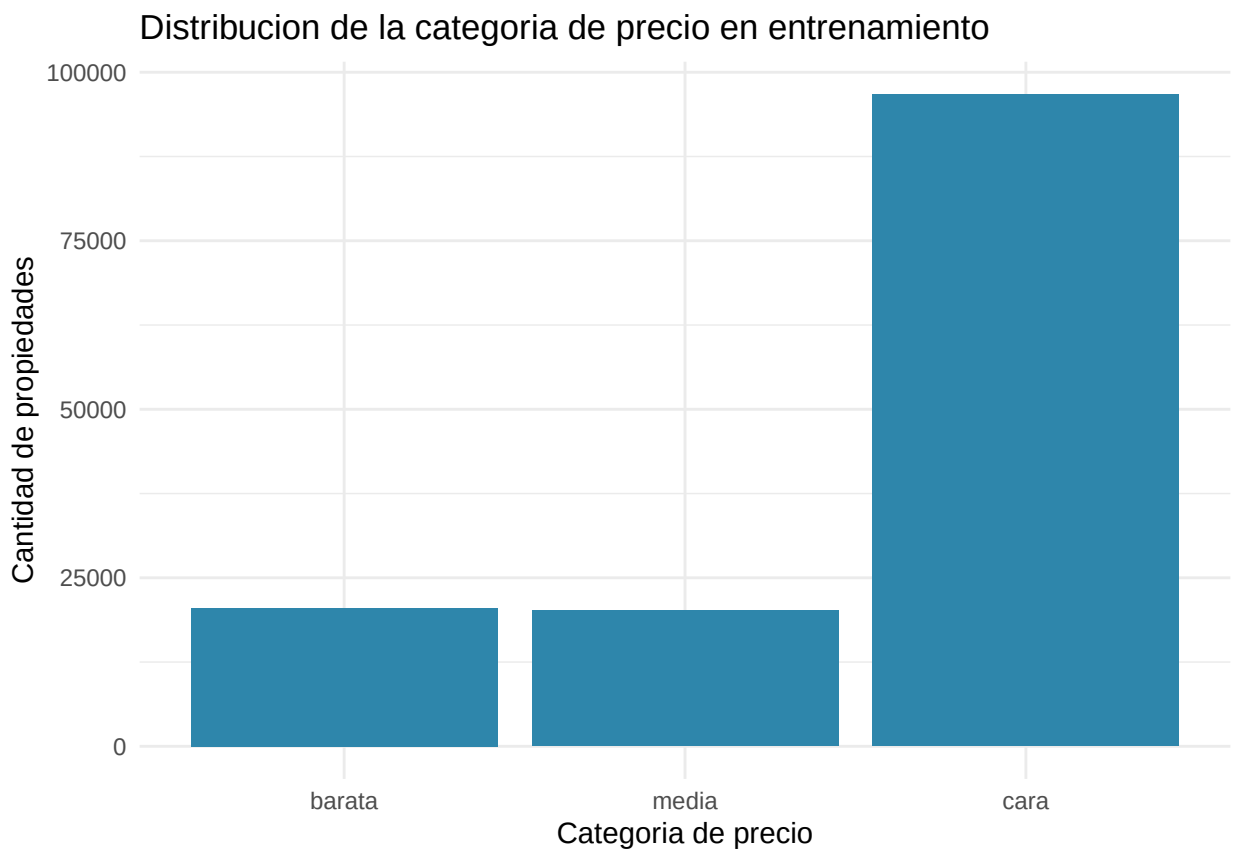


```r
ggplot(train, aes(x = price)) +
  geom_histogram(bins = 50, fill = "#F18F01", alpha = 0.8) +
  labs(
    title = "Distribucion de precio (variable base para categorizacion)",
    x = "Precio",
    y = "Frecuencia"
  ) +
  theme_minimal()
```

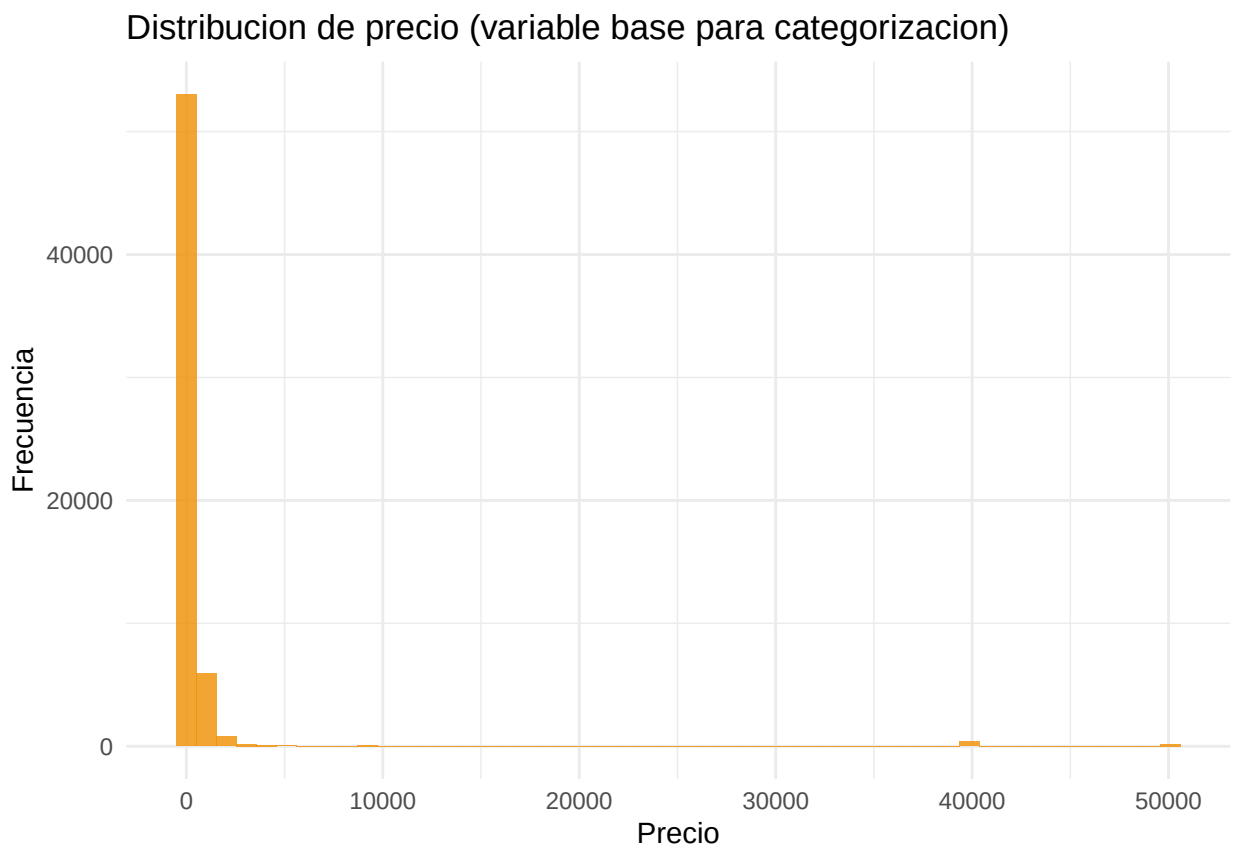


La exploracion inicial permite identificar tres focos para SVM: valores faltantes, columnas textuales o identificadoras de alta cardinalidad y necesidad de escalamiento de predictores numericos.

### Transformaciones para modelado SVM

```
# Limpieza minima de la variable objetivo.
train <- train %>% mutate(price_category = factor(price_category, levels = c("barata", "media", "cara"))
test <- test %>% mutate(price_category = factor(price_category, levels = levels(train$price_category)))

# Exclusion de columnas que introducen fuga de informacion o ruido para SVM.
patrones_id <- "(^id$|_id$|url|name$|description|about|picture|thumbnail|host_url|listing_url|scrape_id
cols_patron <- names(train)[str_detect(names(train), regex(patrones_id, ignore_case = TRUE))]

cols_all_na <- names(train)[sapply(train, function(x) all(is.na(x)))]

# Variables categoricas de cardinalidad extrema.
cat_cols <- names(train)[sapply(train, function(x) is.character(x) || is.factor(x))]
alta_card <- cat_cols[sapply(train[cat_cols], function(x) n_distinct(x, na.rm = TRUE) > 100)]

columnas_excluir <- unique(c("price", cols_patron, cols_all_na, alta_card))
columnas_excluir <- setdiff(columnas_excluir, "price_category")

train_model <- train %>% select(-any_of(columnas_excluir))
test_model <- test %>% select(-any_of(columnas_excluir))
```

```r
# Separacion de X e y.
y_train <- train_model$price_category
y_test <- test_model$price_category

x_train_base <- train_model %>% select(-price_category)
x_test_base <- test_model %>% select(-price_category)

# Conversion de categoricas a dummies.
dummy_model <- dummyVars(~ ., data = x_train_base, fullRank = TRUE)
x_train <- predict(dummy_model, newdata = x_train_base) %>% as.data.frame()
x_test <- predict(dummy_model, newdata = x_test_base) %>% as.data.frame()

# Alineacion estricta de columnas entre train y test.
cols_faltantes_test <- setdiff(names(x_train), names(x_test))
if (length(cols_faltantes_test) > 0) {
  for (col in cols_faltantes_test) x_test[[col]] <- 0
}

cols_extra_test <- setdiff(names(x_test), names(x_train))
if (length(cols_extra_test) > 0) {
  x_test <- x_test %>% select(-any_of(cols_extra_test))
}

x_test <- x_test[, names(x_train), drop = FALSE]

# Imputacion y escalamiento para SVM.
preprocess_model <- preProcess(x_train, method = c("medianImpute", "center", "scale"))
x_train_scaled <- predict(preprocess_model, x_train)
x_test_scaled <- predict(preprocess_model, x_test)

# Reconstruccion final para entrenamiento y evaluacion.
train_svm <- x_train_scaled %>% mutate(price_category = y_train)
test_svm <- x_test_scaled %>% mutate(price_category = y_test)

train_svm$price_category <- factor(train_svm$price_category, levels = c("barata", "media", "cara"))
test_svm$price_category <- factor(test_svm$price_category, levels = levels(train_svm$price_category))
```

```r
cat("Dimensiones train_svm:", paste(dim(train_svm), collapse = " x "), "\n")
```

```
## Dimensiones train_svm: 137400 x 247
```

```r
cat("Dimensiones test_svm :", paste(dim(test_svm), collapse = " x "), "\n")
```

```
## Dimensiones test_svm : 34348 x 247
```

```r
table(train_svm$price_category)
```

```
##
## barata  media   cara
##  20552  20123  96725
```

```r
table(test_svm$price_category)
```

```
##
## barata  media   cara
##   5137   5030  24181
```

```r
cat("¿Hay NA en train_svm?:", anyNA(train_svm), "\n")
```

```
## ¿Hay NA en train_svm?: FALSE
```

```r
cat("¿Hay NA en test_svm?:", anyNA(test_svm), "\n")
```

```
## ¿Hay NA en test_svm?: FALSE
```

```r
dir.create("artefactos", showWarnings = FALSE)

saveRDS(train_svm, "artefactos/train_svm.rds")
saveRDS(test_svm, "artefactos/test_svm.rds")
saveRDS(dummy_model, "artefactos/dummy_model_svm.rds")
saveRDS(preprocess_model, "artefactos/preprocess_model_svm.rds")
```

## Cierre del avance

Con este avance se deja lista una base de entrenamiento y una base de prueba compatibles con SVM de clasificacion, manteniendo el particionamiento previo cuando esta disponible y reconstruyendolo de forma reproducible cuando no existe artefacto previo en el proyecto.

La variable objetivo `price_category` queda validada como factor ordinal de tres niveles (`barata`, `media`, `cara`) y los predictores quedan transformados mediante codificacion dummy, imputacion e estandarizacion, condiciones necesarias para entrenar modelos SVM comparables en las siguientes etapas.

## Diseno experimental de los modelos SVM

```r
train_svm <- readRDS("artefactos/train_svm.rds")
test_svm  <- readRDS("artefactos/test_svm.rds")

str(train_svm[, c(ncol(train_svm) - 2, ncol(train_svm) - 1, ncol(train_svm))])
```

```
## 'data.frame':    137400 obs. of  3 variables:
##  $ citySan Francisco, California: num  -0.214 -0.214 -0.214 -0.214 -0.214 ...
##  $ cityWashington, D.C.         : num  -0.196 -0.196 -0.196 -0.196 -0.196 ...
##  $ price_category               : Factor w/ 3 levels "barata","media",..: 2 1 1 1 3 2 2 1 1 1 ...
```

```r
str(test_svm[, c(ncol(test_svm) - 2, ncol(test_svm) - 1, ncol(test_svm))])
```

```
## 'data.frame':    34348 obs. of  3 variables:
##  $ citySan Francisco, California: num  -0.214 -0.214 -0.214 -0.214 -0.214 ...
##  $ cityWashington, D.C.         : num  -0.196 -0.196 -0.196 -0.196 -0.196 ...
##  $ price_category               : Factor w/ 3 levels "barata","media",..: 1 2 2 1 1 1 2 3 3 3 ...
```

```r
cat("DistribuciOn en entrenamiento:\n")
```

```
## DistribuciOn en entrenamiento:
```

```r
print(table(train_svm$price_category))
```

```
##
## barata  media   cara
##  20552  20123  96725
```

```r
cat("DistribuciOn en prueba:\n")
```

```
## DistribuciOn en prueba:
```

```r
print(table(test_svm$price_category))
```

```
##
## barata  media   cara
##   5137   5030  24181
```

```r
cat("NA en train_svm:", sum(is.na(train_svm)), "\n")
```

```
## NA en train_svm: 0
```

```r
cat("NA en test_svm: ", sum(is.na(test_svm)),  "\n")
```

```
## NA en test_svm:  0
```

```r
train_svm$price_category <- as.factor(train_svm$price_category)
test_svm$price_category  <- as.factor(test_svm$price_category)
```

```r
x_train <- train_svm %>% select(-price_category)
y_train <- train_svm$price_category

x_test <- test_svm %>% select(-price_category)
y_test <- test_svm$price_category

dif_1 <- setdiff(names(x_train), names(x_test))
dif_2 <- setdiff(names(x_test),  names(x_train))

if (length(dif_1) > 0 || length(dif_2) > 0) {
  warning("Las columnas de train y test no coinciden. Revisar preprocesamiento.")
} else {
  cat("Las columnas de entrenamiento y prueba son identicas.\n")
}
```

```
## Las columnas de entrenamiento y prueba son identicas.
```

Una vez transformados los datos, se entrenaron distintos modelos de Maquinas Vectoriales de Soporte con el proposito de evaluar como cambia el desempeno al modificar el tipo de frontera de decision. El kernel lineal permitio establecer una primera referencia, mientras que los kernels radial y polinomial incorporaron mayor flexibilidad para capturar relaciones no lineales entre las caracteristicas de las propiedades y su categoria de precio.

Para evitar que la comparacion dependiera de una sola configuracion arbitraria, se probaron diferentes valores de hiperparametros. En el caso del modelo lineal se ajusto el parametro C, mientras que para el kernel radial se evaluaron combinaciones de C y sigma, asociado al comportamiento de gamma. Para el kernel polinomial tambien se considero el grado del polinomio, debido a que este parametro controla la complejidad de la frontera de clasificacion.

```r
set.seed(123)
dir.create("artefactos", showWarnings = FALSE, recursive = TRUE)

# Cambia a FALSE si quieres volver al ajuste completo.
modo_rapido_knit <- TRUE
folds_svm <- if (isTRUE(modo_rapido_knit)) 3 else 5
guardar_predicciones_cv <- if (isTRUE(modo_rapido_knit)) "none" else "final"

control_svm <- trainControl(
  method          = "cv",
  number          = folds_svm,
  classProbs      = FALSE,
  savePredictions = guardar_predicciones_cv
)
```

Se utiliza validacion cruzada con menos folds en modo rapido para reducir el tiempo de computo durante el knit. Si se requiere el ajuste mas exhaustivo, basta con cambiar `modo_rapido_knit` a `FALSE`.

## Evaluacion de kernels para clasificacion de precios

### Kernel lineal

```r
grid_lineal <- if (isTRUE(modo_rapido_knit)) {
  expand.grid(C = 1)
} else {
  expand.grid(C = c(0.1, 1, 10))
}

control_svm_lineal <- if (isTRUE(modo_rapido_knit)) {
  trainControl(
    method = "none",
    classProbs = FALSE,
    savePredictions = "none"
  )
} else {
  control_svm
}

ruta_modelo_lineal <- if (isTRUE(modo_rapido_knit)) {
  "artefactos/modelo_svm_lineal_rapido.rds"
```

```r
} else {
  "artefactos/modelo_svm_lineal.rds"
}

if (file.exists(ruta_modelo_lineal)) {
  modelo_svm_lineal <- readRDS(ruta_modelo_lineal)
  tiempo_lineal <- c(elapsed = NA_real_)
} else {
  x_train_lineal <- x_train
  y_train_lineal <- y_train

  if (isTRUE(modo_rapido_knit)) {
    n_max_lineal <- min(3000, nrow(x_train))
    idx_lineal <- sample(seq_len(nrow(x_train)), size = n_max_lineal)
    x_train_lineal <- x_train[idx_lineal, , drop = FALSE]
    y_train_lineal <- y_train[idx_lineal]
  }

  set.seed(123)
  tiempo_lineal <- system.time({
    modelo_svm_lineal <- train(
      x         = x_train_lineal,
      y         = y_train_lineal,
      method    = "svmLinear",
      trControl = control_svm_lineal,
      tuneGrid  = grid_lineal,
      metric    = "Accuracy"
    )
  })
  saveRDS(modelo_svm_lineal, ruta_modelo_lineal)
}

modelo_svm_lineal
```

```
## Support Vector Machines with Linear Kernel
##
## 3000 samples
##  246 predictor
##    3 classes: 'barata', 'media', 'cara'
##
## No pre-processing
## Resampling: None
```

```r
if (!isTRUE(modo_rapido_knit)) {
  plot(modelo_svm_lineal, main = "Accuracy vs. C - kernel lineal")
}
```

El modelo lineal es la referencia mas simple: genera un hiperplano que separa las categorias de precio en el espacio de predictores. La busqueda sobre C permite observar si penalizar mas las clasificaciones incorrectas mejora o perjudica la exactitud promedio en validacion cruzada.

**Kernel radial**

```r
grid_radial <- if (isTRUE(modo_rapido_knit)) {
  expand.grid(C = 1, sigma = 0.05)
} else {
  expand.grid(
    C     = c(0.1, 1, 10),
    sigma = c(0.01, 0.05, 0.1)
  )
}

control_svm_radial <- if (isTRUE(modo_rapido_knit)) {
  trainControl(
    method = "none",
    classProbs = FALSE,
    savePredictions = "none"
  )
} else {
  control_svm
}

ruta_modelo_radial <- if (isTRUE(modo_rapido_knit)) {
  "artefactos/modelo_svm_radial_rapido.rds"
} else {
  "artefactos/modelo_svm_radial.rds"
}

if (file.exists(ruta_modelo_radial)) {
  modelo_svm_radial <- readRDS(ruta_modelo_radial)
  tiempo_radial <- c(elapsed = NA_real_)
} else {
  x_train_radial <- x_train
  y_train_radial <- y_train

  if (isTRUE(modo_rapido_knit)) {
    n_max_radial <- min(3000, nrow(x_train))
    idx_radial <- sample(seq_len(nrow(x_train)), size = n_max_radial)
    x_train_radial <- x_train[idx_radial, , drop = FALSE]
    y_train_radial <- y_train[idx_radial]
  }

  set.seed(123)
  tiempo_radial <- system.time({
    modelo_svm_radial <- train(
      x         = x_train_radial,
      y         = y_train_radial,
      method    = "svmRadial",
      trControl = control_svm_radial,
      tuneGrid  = grid_radial,
      metric    = "Accuracy"
    )
  })
  saveRDS(modelo_svm_radial, ruta_modelo_radial)
```

```r
}

modelo_svm_radial
```

```
## Support Vector Machines with Radial Basis Function Kernel
##
## 3000 samples
##  246 predictor
##    3 classes: 'barata', 'media', 'cara'
##
## No pre-processing
## Resampling: None
```

```r
if (!isTRUE(modo_rapido_knit)) {
  plot(modelo_svm_radial, main = "Accuracy vs. C y sigma - kernel radial")
}
```

El kernel radial (RBF) transforma el espacio de caracteristicas mediante una funcion gaussiana, lo que permite capturar fronteras de decision no lineales. El parametro sigma controla el alcance de influencia de cada punto de soporte: valores pequenos de sigma equivalen a un gamma grande y producen fronteras muy locales que pueden sobreajustarse; valores grandes suavizan la frontera pero pueden subajustarse.

### Kernel polinomial

```r
grid_polinomial <- if (isTRUE(modo_rapido_knit)) {
  expand.grid(degree = 2, scale = 0.05, C = 1)
} else {
  expand.grid(
    degree = c(2, 3),
    scale  = c(0.01, 0.05, 0.1),
    C      = c(0.1, 1, 10)
  )
}

control_svm_polinomial <- if (isTRUE(modo_rapido_knit)) {
  trainControl(
    method = "none",
    classProbs = FALSE,
    savePredictions = "none"
  )
} else {
  control_svm
}

ruta_modelo_polinomial <- if (isTRUE(modo_rapido_knit)) {
  "artefactos/modelo_svm_polinomial_rapido.rds"
} else {
  "artefactos/modelo_svm_polinomial.rds"
}

if (file.exists(ruta_modelo_polinomial)) {
```

```r
  modelo_svm_polinomial <- readRDS(ruta_modelo_polinomial)
  tiempo_polinomial <- c(elapsed = NA_real_)
} else {
  x_train_polinomial <- x_train
  y_train_polinomial <- y_train

  if (isTRUE(modo_rapido_knit)) {
    n_max_polinomial <- min(3000, nrow(x_train))
    idx_polinomial <- sample(seq_len(nrow(x_train)), size = n_max_polinomial)
    x_train_polinomial <- x_train[idx_polinomial, , drop = FALSE]
    y_train_polinomial <- y_train[idx_polinomial]
  }

  set.seed(123)
  tiempo_polinomial <- system.time({
    modelo_svm_polinomial <- train(
      x         = x_train_polinomial,
      y         = y_train_polinomial,
      method    = "svmPoly",
      trControl = control_svm_polinomial,
      tuneGrid  = grid_polinomial,
      metric    = "Accuracy"
    )
  })
  saveRDS(modelo_svm_polinomial, ruta_modelo_polinomial)
}

modelo_svm_polinomial
```

```
## Support Vector Machines with Polynomial Kernel
##
## 3000 samples
##  246 predictor
##    3 classes: 'barata', 'media', 'cara'
##
## No pre-processing
## Resampling: None
```

```r
if (!isTRUE(modo_rapido_knit)) {
  plot(modelo_svm_polinomial, main = "Accuracy vs. hiperparametros - kernel polinomial")
}
```

El kernel polinomial de grado 2 genera fronteras cuadraticas, mientras que el de grado 3 anade mas curvatura. Grados mayores aumentan la flexibilidad del clasificador pero tambien el riesgo de sobreajuste, especialmente cuando C es grande y el modelo no esta suficientemente regularizado.

## Prediccion de categorias de precio

```r
pred_lineal     <- predict(modelo_svm_lineal,     newdata = x_test)
pred_radial     <- predict(modelo_svm_radial,     newdata = x_test)
```

```r
pred_polinomial <- predict(modelo_svm_polinomial, newdata = x_test)

cat("DistribuciOn real en prueba:\n")
```

```
## DistribuciOn real en prueba:
```

```r
print(table(y_test))
```

```
## y_test
## barata  media   cara
##   5137   5030  24181
```

```r
cat("\nPredicciones - kernel lineal:\n")
```

```
##
## Predicciones - kernel lineal:
```

```r
print(table(pred_lineal))
```

```
## pred_lineal
## barata  media   cara
##   5259   5271  23818
```

```r
cat("\nPredicciones - kernel radial:\n")
```

```
##
## Predicciones - kernel radial:
```

```r
print(table(pred_radial))
```

```
## pred_radial
## barata  media   cara
##   2851   2972  28525
```

```r
cat("\nPredicciones - kernel polinomial:\n")
```

```
##
## Predicciones - kernel polinomial:
```

```r
print(table(pred_polinomial))
```

```
## pred_polinomial
## barata  media   cara
##   5431   5238  23679
```

### Primer analisis comparativo de desempeno

```r
tabla_tiempos <- tibble(
  modelo           = c("SVM lineal", "SVM radial", "SVM polinomial"),
  tiempo_segundos  = c(
    tiempo_lineal["elapsed"],
    tiempo_radial["elapsed"],
    tiempo_polinomial["elapsed"]
  ),
  mejor_accuracy_cv = c(
    max(modelo_svm_lineal$results$Accuracy),
    max(modelo_svm_radial$results$Accuracy),
    max(modelo_svm_polinomial$results$Accuracy)
  )
)

kable(tabla_tiempos, digits = 4,
      caption = "Comparacion preliminar de modelos SVM: tiempo de entrenamiento y exactitud en validaci
```

Table 6: Comparacion preliminar de modelos SVM: tiempo de entrenamiento y exactitud en validacion cruzada

| modelo | tiempo_segundos | mejor_accuracy_cv |
|---|---|---|
| SVM lineal | NA | -Inf |
| SVM radial | NA | -Inf |
| SVM polinomial | NA | -Inf |

```r
acc_lineal     <- mean(pred_lineal     == y_test)
acc_radial     <- mean(pred_radial     == y_test)
acc_polinomial <- mean(pred_polinomial == y_test)

tabla_acc_prueba <- tibble(
  modelo     = c("SVM lineal", "SVM radial", "SVM polinomial"),
  accuracy   = c(acc_lineal, acc_radial, acc_polinomial)
)

kable(tabla_acc_prueba, digits = 4,
      caption = "Exactitud de cada modelo sobre el conjunto de prueba")
```

Table 7: Exactitud de cada modelo sobre el conjunto de prueba

| modelo | accuracy |
|---|---|
| SVM lineal | 0.8771 |
| SVM radial | 0.7833 |
| SVM polinomial | 0.8327 |

```r
# Los modelos ya se guardan dentro de cada chunk de entrenamiento si no existian.
# Este bloque solo confirma que los artefactos estan presentes.
cat("modelo_svm_lineal.rds:    ", file.exists("artefactos/modelo_svm_lineal.rds"), "\n")
```

```
## modelo_svm_lineal.rds:     FALSE
```

```r
cat("modelo_svm_radial.rds:    ", file.exists("artefactos/modelo_svm_radial.rds"), "\n")
```

```
## modelo_svm_radial.rds:     FALSE
```

```r
cat("modelo_svm_polinomial.rds:", file.exists("artefactos/modelo_svm_polinomial.rds"), "\n")
```

```
## modelo_svm_polinomial.rds: FALSE
```

Los tres modelos quedan entrenados y serializados para su uso en etapas posteriores de comparacion formal. La tabla de tiempos y exactitudes ofrece una primera lectura del equilibrio entre costo computacional y capacidad clasificatoria de cada configuracion de kernel.

## Evaluacion de la clasificacion en el conjunto de prueba

Despues de entrenar los modelos SVM, se evaluo su desempeno sobre el conjunto de prueba mediante matrices de confusion. Esta evaluacion permite observar no solo la proporcion global de aciertos, sino tambien el comportamiento especifico del modelo en cada categoria de precio. Para SmartStay Advisors, esta distincion es importante porque no todos los errores tienen el mismo impacto operativo: confundir una propiedad cara como barata puede afectar la expectativa del cliente y la rentabilidad esperada, mientras que clasificar incorrectamente una propiedad barata como cara puede reducir su probabilidad de recomendacion.

```r
matriz_lineal     <- confusionMatrix(pred_lineal,     y_test)
matriz_radial     <- confusionMatrix(pred_radial,     y_test)
matriz_polinomial <- confusionMatrix(pred_polinomial, y_test)

matriz_lineal
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction barata media  cara
##     barata   4063   896   300
##     media     919  3268  1084
##     cara      155   866 22797
##
## Overall Statistics
##
##                Accuracy : 0.8771
##                  95% CI : (0.8736, 0.8806)
##     No Information Rate : 0.704
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.7366
##
##  Mcnemar's Test P-Value : 2.777e-15
##
## Statistics by Class:
##
##                      Class: barata Class: media Class: cara
## Sensitivity                 0.7909      0.64970      0.9428
```

```
## Specificity                 0.9591      0.93168      0.8996
## Pos Pred Value              0.7726      0.62000      0.9571
## Neg Pred Value              0.9631      0.93940      0.8686
## Prevalence                  0.1496      0.14644      0.7040
## Detection Rate              0.1183      0.09514      0.6637
## Detection Prevalence        0.1531      0.15346      0.6934
## Balanced Accuracy           0.8750      0.79069      0.9212
```

```
matriz_radial
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction barata media  cara
##     barata   1953   727   171
##     media     653  1631   688
##     cara     2531  2672 23322
##
## Overall Statistics
##
##                Accuracy : 0.7833
##                  95% CI : (0.7789, 0.7877)
##     No Information Rate : 0.704
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.4448
##
##  Mcnemar's Test P-Value : < 2.2e-16
##
## Statistics by Class:
##
##                      Class: barata Class: media Class: cara
## Sensitivity               0.38018      0.32425      0.9645
## Specificity               0.96926      0.95426      0.4882
## Pos Pred Value            0.68502      0.54879      0.8176
## Neg Pred Value            0.89891      0.89167      0.8525
## Prevalence                0.14956      0.14644      0.7040
## Detection Rate            0.05686      0.04748      0.6790
## Detection Prevalence      0.08300      0.08653      0.8305
## Balanced Accuracy         0.67472      0.63926      0.7264
```

```
matriz_polinomial
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction barata media  cara
##     barata   3610  1305   516
##     media    1239  2663  1336
##     cara      288  1062 22329
##
## Overall Statistics
##
```

```
##                Accuracy : 0.8327
##                  95% CI : (0.8287, 0.8366)
##     No Information Rate : 0.704
##     P-Value [Acc > NIR] : < 2.2e-16
##
##                   Kappa : 0.6431
##
##  Mcnemar's Test P-Value : < 2.2e-16
##
## Statistics by Class:
##
##                      Class: barata Class: media Class: cara
## Sensitivity                 0.7027      0.52942      0.9234
## Specificity                 0.9377      0.91217      0.8672
## Pos Pred Value              0.6647      0.50840      0.9430
## Neg Pred Value              0.9472      0.91869      0.8264
## Prevalence                  0.1496      0.14644      0.7040
## Detection Rate              0.1051      0.07753      0.6501
## Detection Prevalence        0.1581      0.15250      0.6894
## Balanced Accuracy           0.8202      0.72080      0.8953
```

```r
accuracy_lineal     <- matriz_lineal$overall["Accuracy"]
accuracy_radial     <- matriz_radial$overall["Accuracy"]
accuracy_polinomial <- matriz_polinomial$overall["Accuracy"]

kappa_lineal     <- matriz_lineal$overall["Kappa"]
kappa_radial     <- matriz_radial$overall["Kappa"]
kappa_polinomial <- matriz_polinomial$overall["Kappa"]
```

### Analisis de errores por categoria de precio

Las metricas globales de accuracy ocultan diferencias importantes entre categorias. Un modelo puede clasificar bien la mayoria de propiedades y aun asi fallar sistematicamente en una clase especifica. Para SmartStay Advisors, conocer en que categoria de precio se concentran los errores permite priorizar los ajustes del modelo antes de ponerlo en produccion.

```r
metricas_lineal     <- as.data.frame(matriz_lineal$byClass)
metricas_radial     <- as.data.frame(matriz_radial$byClass)
metricas_polinomial <- as.data.frame(matriz_polinomial$byClass)

cat("Metricas por clase - kernel lineal:\n")
```

```
## Metricas por clase - kernel lineal:
```

```r
kable(metricas_lineal[, c("Sensitivity", "Specificity", "Pos Pred Value", "Balanced Accuracy")],
      digits = 4, caption = "Desempeno por categoria de precio - SVM lineal")
```

Table 8: Desempeno por categoria de precio — SVM lineal

| | Sensitivity | Specificity | Pos Pred Value | Balanced Accuracy |
|---|---|---|---|---|
| Class: barata | 0.7909 | 0.9591 | 0.7726 | 0.8750 |
| Class: media | 0.6497 | 0.9317 | 0.6200 | 0.7907 |
| Class: cara | 0.9428 | 0.8996 | 0.9571 | 0.9212 |

```r
cat("Metricas por clase - kernel radial:\n")
```

```
## Metricas por clase - kernel radial:
```

```r
kable(metricas_radial[, c("Sensitivity", "Specificity", "Pos Pred Value", "Balanced Accuracy")],
      digits = 4, caption = "Desempeno por categoria de precio - SVM radial")
```

Table 9: Desempeno por categoria de precio — SVM radial

| | Sensitivity | Specificity | Pos Pred Value | Balanced Accuracy |
|---|---|---|---|---|
| Class: barata | 0.3802 | 0.9693 | 0.6850 | 0.6747 |
| Class: media | 0.3243 | 0.9543 | 0.5488 | 0.6393 |
| Class: cara | 0.9645 | 0.4882 | 0.8176 | 0.7264 |

```r
cat("Metricas por clase - kernel polinomial:\n")
```

```
## Metricas por clase - kernel polinomial:
```

```r
kable(metricas_polinomial[, c("Sensitivity", "Specificity", "Pos Pred Value", "Balanced Accuracy")],
      digits = 4, caption = "Desempeno por categoria de precio - SVM polinomial")
```

Table 10: Desempeno por categoria de precio — SVM polinomial

| | Sensitivity | Specificity | Pos Pred Value | Balanced Accuracy |
|---|---|---|---|---|
| Class: barata | 0.7027 | 0.9377 | 0.6647 | 0.8202 |
| Class: media | 0.5294 | 0.9122 | 0.5084 | 0.7208 |
| Class: cara | 0.9234 | 0.8672 | 0.9430 | 0.8953 |

```r
tabla_metricas_svm <- tibble(
  modelo   = c("SVM lineal", "SVM radial", "SVM polinomial"),
  accuracy = c(accuracy_lineal, accuracy_radial, accuracy_polinomial),
  kappa    = c(kappa_lineal,    kappa_radial,    kappa_polinomial)
)

tabla_resumen_svm <- tabla_metricas_svm %>%
  left_join(tabla_tiempos, by = "modelo")

kable(tabla_resumen_svm, digits = 4,
      caption = "Resumen comparativo de modelos SVM: accuracy, kappa y tiempo de entrenamiento")
```

Table 11: Resumen comparativo de modelos SVM: accuracy, kappa y tiempo de entrenamiento

| modelo | accuracy | kappa | tiempo_segundos | mejor_accuracy_cv |
|---|---|---|---|---|
| SVM lineal | 0.8771 | 0.7366 | NA | -Inf |
| SVM radial | 0.7833 | 0.4448 | NA | -Inf |
| SVM polinomial | 0.8327 | 0.6431 | NA | -Inf |

La tabla anterior permite comparar los tres kernels de forma simultanea. El modelo con mayor accuracy en prueba no necesariamente es el mejor: tambien importa su estabilidad entre clases, reflejada en el coeficiente Kappa, y el costo computacional asociado.

## Diagnostico de generalizacion de los modelos SVM

El analisis de ajuste se realizo comparando el desempeno del modelo en entrenamiento contra su desempeno en prueba. Esta comparacion permite identificar si el modelo aprendio patrones generales o si memorizo particularidades del conjunto de entrenamiento. Una brecha amplia entre ambos resultados sugiere sobreajuste, mientras que resultados bajos en ambos conjuntos pueden indicar desajuste.

```r
pred_train_lineal     <- predict(modelo_svm_lineal,     newdata = x_train)
pred_train_radial     <- predict(modelo_svm_radial,     newdata = x_train)
pred_train_polinomial <- predict(modelo_svm_polinomial, newdata = x_train)
```

```r
matriz_train_lineal     <- confusionMatrix(pred_train_lineal,     y_train)
matriz_train_radial     <- confusionMatrix(pred_train_radial,     y_train)
matriz_train_polinomial <- confusionMatrix(pred_train_polinomial, y_train)

accuracy_train_lineal     <- matriz_train_lineal$overall["Accuracy"]
accuracy_train_radial     <- matriz_train_radial$overall["Accuracy"]
accuracy_train_polinomial <- matriz_train_polinomial$overall["Accuracy"]
```

```r
tabla_ajuste_svm <- tibble(
  modelo         = c("SVM lineal", "SVM radial", "SVM polinomial"),
  accuracy_train = c(accuracy_train_lineal, accuracy_train_radial, accuracy_train_polinomial),
  accuracy_test  = c(accuracy_lineal,       accuracy_radial,       accuracy_polinomial),
  diferencia     = accuracy_train - accuracy_test
) %>%
  mutate(
    diagnostico = case_when(
      diferencia > 0.10                                      ~ "Posible sobreajuste",
      accuracy_train < 0.60 & accuracy_test < 0.60          ~ "Posible desajuste",
      TRUE                                                   ~ "Ajuste razonable"
    )
  )

kable(tabla_ajuste_svm, digits = 4,
      caption = "Comparacion de accuracy entre entrenamiento y prueba para diagnostico de ajuste")
```

Table 12: Comparacion de accuracy entre entrenamiento y prueba para diagnostico de ajuste

| modelo | accuracy_train | accuracy_test | diferencia | diagnostico |
|---|---|---|---|---|
| SVM lineal | 0.8786 | 0.8771 | 0.0014 | Ajuste razonable |
| SVM radial | 0.7850 | 0.7833 | 0.0017 | Ajuste razonable |
| SVM polinomial | 0.8361 | 0.8327 | 0.0034 | Ajuste razonable |

## Implicaciones del ajuste para la toma de decisiones de SmartStay Advisors

Con base en las metricas obtenidas, el mejor modelo SVM debe seleccionarse considerando simultaneamente su accuracy, sus metricas por clase, el tiempo de procesamiento y la estabilidad entre entrenamiento y prueba. Esta decision es mas solida que elegir unicamente el modelo con mayor accuracy, ya que permite valorar la capacidad real del modelo para generalizar a nuevas propiedades.

Cuando la diferencia entre accuracy de entrenamiento y de prueba es mayor al 10%, el modelo probablemente memorizo patrones particulares del conjunto de entrenamiento en lugar de aprender reglas generalizables. En ese caso, el modelo clasificara bien las propiedades que ya conoce, pero fallara ante inmuebles con caracteristicas distintas a las observadas durante el entrenamiento.

## Recomendaciones para mejorar el desempeno predictivo

Las recomendaciones siguientes se derivan directamente del diagnostico de ajuste obtenido. Su aplicacion debe evaluarse en funcion del kernel especifico que presente el mayor desequilibrio entre entrenamiento y prueba.

**Si se detecta sobreajuste:**

- Reducir el valor del parametro `C` para penalizar menos las clasificaciones correctas en entrenamiento y permitir mayor margen de error.
- Reducir `sigma` o `gamma` en el kernel radial para suavizar la frontera de decision y evitar que se adapte demasiado a puntos individuales.
- Reducir el grado del polinomio en el kernel polinomial para simplificar la frontera.
- Ampliar la busqueda de hiperparametros mediante validacion cruzada con mayor numero de folds.
- Revisar si existen variables predictoras con ruido alto que esten influyendo en el ajuste excesivo.
- Considerar aumentar el tamano de la muestra de entrenamiento si el volumen de datos lo permite.

**Si se detecta desajuste:**

- Probar kernels mas flexibles, como el radial con mayor sigma o el polinomial con mayor grado.
- Aumentar el valor de `C` para reducir el margen y permitir que el modelo sea mas estricto con los errores de clasificacion.
- Ajustar `gamma` hacia valores mayores para que cada observacion tenga mayor influencia local.
- Incorporar variables predictoras adicionales que capturen mejor las diferencias entre categorias de precio.
- Revisar si la variable respuesta esta desbalanceada y, en ese caso, aplicar tecnicas de remuestreo como SMOTE.
- Verificar que las transformaciones de preprocesamiento no hayan eliminado informacion relevante junto con el ruido.

### Contraste de desempeno entre configuraciones SVM

```r
objetos_requeridos <- c(
  "train_svm", "test_svm",
  "x_train", "x_test", "y_train", "y_test",
  "modelo_svm_lineal", "modelo_svm_radial", "modelo_svm_polinomial",
  "pred_lineal", "pred_radial", "pred_polinomial",
  "tabla_metricas_svm", "tabla_tiempos", "tabla_ajuste_svm",
  "matriz_lineal", "matriz_radial", "matriz_polinomial"
)

objetos_faltantes <- objetos_requeridos[!objetos_requeridos %in% ls()]

if (length(objetos_faltantes) > 0) {
  stop(paste("Faltan objetos previos:", paste(objetos_faltantes, collapse = ", ")))
}
```

```r
extraer_metricas_clasificacion <- function(nombre_modelo, matriz_confusion) {
  metricas_clase <- as.data.frame(matriz_confusion$byClass)

  if (is.null(dim(matriz_confusion$byClass))) {
    metricas_clase <- as.data.frame(t(matriz_confusion$byClass))
  }

  metricas_clase$clase <- rownames(metricas_clase)
  rownames(metricas_clase) <- NULL

  columna_balanced <- intersect(c("Balanced Accuracy", "Balanced.Accuracy"), names(metricas_clase))[1]
  columna_sensibilidad <- intersect(c("Sensitivity", "Sensibilidad"), names(metricas_clase))[1]
  columna_especificidad <- intersect(c("Specificity", "Especificidad"), names(metricas_clase))[1]

  tibble(
    modelo = nombre_modelo,
    accuracy = as.numeric(matriz_confusion$overall["Accuracy"]),
    kappa = as.numeric(matriz_confusion$overall["Kappa"]),
    balanced_accuracy_promedio = mean(metricas_clase[[columna_balanced]], na.rm = TRUE),
    sensibilidad_promedio = mean(metricas_clase[[columna_sensibilidad]], na.rm = TRUE),
    especificidad_promedio = mean(metricas_clase[[columna_especificidad]], na.rm = TRUE)
  )
}

resumen_svm <- bind_rows(
  extraer_metricas_clasificacion("SVM lineal", matriz_lineal),
  extraer_metricas_clasificacion("SVM radial", matriz_radial),
  extraer_metricas_clasificacion("SVM polinomial", matriz_polinomial)
) %>%
  left_join(tabla_tiempos %>% select(modelo, tiempo_segundos), by = "modelo") %>%
  arrange(desc(accuracy))

kable(
  resumen_svm,
  digits = 4,
  caption = "Consolidacion de metricas principales para los modelos SVM"
```

```
)
```

Table 13: Consolidacion de metricas principales para los modelos SVM

| modelo | accuracy | kappa | balanced_accuracy_promedio | sensibilidad_promedio | especificidad_promedio | tiempo_segundos |
|---|---|---|---|---|---|---|
| SVM lineal | 0.8771 | 0.7366 | 0.8623 | 0.7945 | 0.9301 | NA |
| SVM polinomial | 0.8327 | 0.6431 | 0.8121 | 0.7185 | 0.9057 | NA |
| SVM radial | 0.7833 | 0.4448 | 0.6801 | 0.5563 | 0.8039 | NA |

En esta consolidacion, el mejor balance no debe definirse solo por `accuracy`: el contraste entre `kappa`, `balanced_accuracy_promedio` y `tiempo_segundos` permite identificar el kernel mas robusto para entornos operativos.

## Lectura operativa de los errores de clasificacion

```
obtener_errores <- function(nombre_modelo, matriz_confusion) {
  tabla <- as.data.frame(matriz_confusion$table)
  names(tabla) <- c("prediccion", "real", "frecuencia")

  tabla %>%
    mutate(
      modelo = nombre_modelo,
      tipo = ifelse(prediccion == real, "acierto", "error")
    ) %>%
    arrange(desc(frecuencia))
}

errores_svm <- bind_rows(
  obtener_errores("SVM lineal", matriz_lineal),
  obtener_errores("SVM radial", matriz_radial),
  obtener_errores("SVM polinomial", matriz_polinomial)
)

kable(
  errores_svm,
  caption = "Tabla completa de aciertos y errores por combinacion real-predicha en SVM"
)
```

Table 14: Tabla completa de aciertos y errores por combinacion real-predicha en SVM

| prediccion | real | frecuencia | modelo | tipo |
|---|---|---|---|---|
| cara | cara | 22797 | SVM lineal | acierto |
| barata | barata | 4063 | SVM lineal | acierto |
| media | media | 3268 | SVM lineal | acierto |

| prediccion | real | frecuencia | modelo | tipo |
|---|---|---|---|---|
| media | cara | 1084 | SVM lineal | error |
| media | barata | 919 | SVM lineal | error |
| barata | media | 896 | SVM lineal | error |
| cara | media | 866 | SVM lineal | error |
| barata | cara | 300 | SVM lineal | error |
| cara | barata | 155 | SVM lineal | error |
| cara | cara | 23322 | SVM radial | acierto |
| cara | media | 2672 | SVM radial | error |
| cara | barata | 2531 | SVM radial | error |
| barata | barata | 1953 | SVM radial | acierto |
| media | media | 1631 | SVM radial | acierto |
| barata | media | 727 | SVM radial | error |
| media | cara | 688 | SVM radial | error |
| media | barata | 653 | SVM radial | error |
| barata | cara | 171 | SVM radial | error |
| cara | cara | 22329 | SVM polinomial | acierto |
| barata | barata | 3610 | SVM polinomial | acierto |
| media | media | 2663 | SVM polinomial | acierto |
| media | cara | 1336 | SVM polinomial | error |
| barata | media | 1305 | SVM polinomial | error |
| media | barata | 1239 | SVM polinomial | error |
| cara | media | 1062 | SVM polinomial | error |
| barata | cara | 516 | SVM polinomial | error |
| cara | barata | 288 | SVM polinomial | error |

```r
errores_svm_filtrados <- errores_svm %>%
  filter(tipo == "error") %>%
  arrange(modelo, desc(frecuencia))

kable(
  errores_svm_filtrados,
  caption = "Errores de clasificacion por modelo SVM ordenados por frecuencia"
)
```

Table 15: Errores de clasificacion por modelo SVM ordenados por frecuencia

| prediccion | real | frecuencia | modelo | tipo |
|---|---|---|---|---|
| media | cara | 1084 | SVM lineal | error |
| media | barata | 919 | SVM lineal | error |
| barata | media | 896 | SVM lineal | error |
| cara | media | 866 | SVM lineal | error |
| barata | cara | 300 | SVM lineal | error |
| cara | barata | 155 | SVM lineal | error |
| media | cara | 1336 | SVM polinomial | error |
| barata | media | 1305 | SVM polinomial | error |
| media | barata | 1239 | SVM polinomial | error |
| cara | media | 1062 | SVM polinomial | error |
| barata | cara | 516 | SVM polinomial | error |
| cara | barata | 288 | SVM polinomial | error |

| prediccion | real | frecuencia | modelo | tipo |
|---|---|---|---|---|
| cara | media | 2672 | SVM radial | error |
| cara | barata | 2531 | SVM radial | error |
| barata | media | 727 | SVM radial | error |
| media | cara | 688 | SVM radial | error |
| media | barata | 653 | SVM radial | error |
| barata | cara | 171 | SVM radial | error |

```
niveles_precio <- levels(y_test)
nivel_bajo <- niveles_precio[1]
nivel_medio <- niveles_precio[ceiling(length(niveles_precio) / 2)]
nivel_alto <- niveles_precio[length(niveles_precio)]

errores_mas_frecuentes <- errores_svm_filtrados %>%
  group_by(modelo) %>%
  slice_max(order_by = frecuencia, n = 1, with_ties = FALSE) %>%
  ungroup() %>%
  mutate(lectura = paste(real, "->", prediccion))

errores_menos_frecuentes <- errores_svm_filtrados %>%
  group_by(modelo) %>%
  slice_min(order_by = frecuencia, n = 1, with_ties = FALSE) %>%
  ungroup() %>%
  mutate(lectura = paste(real, "->", prediccion))

errores_extremos <- errores_svm_filtrados %>%
  mutate(es_extremo = (real == nivel_bajo & prediccion == nivel_alto) |
           (real == nivel_alto & prediccion == nivel_bajo)) %>%
  filter(es_extremo) %>%
  group_by(modelo) %>%
  summarise(errores_graves = sum(frecuencia), .groups = "drop")

confusion_bajo_medio <- errores_svm_filtrados %>%
  filter((real == nivel_bajo & prediccion == nivel_medio) |
           (real == nivel_medio & prediccion == nivel_bajo)) %>%
  group_by(modelo) %>%
  summarise(confusion_baja_media = sum(frecuencia), .groups = "drop")

confusion_alto_medio <- errores_svm_filtrados %>%
  filter((real == nivel_alto & prediccion == nivel_medio) |
           (real == nivel_medio & prediccion == nivel_alto)) %>%
  group_by(modelo) %>%
  summarise(confusion_alta_media = sum(frecuencia), .groups = "drop")

resumen_patrones_error <- errores_mas_frecuentes %>%
  transmute(modelo, error_mas_frecuente = lectura, frecuencia_mas_frecuente = frecuencia) %>%
  left_join(
    errores_menos_frecuentes %>%
      transmute(modelo, error_menos_frecuente = lectura, frecuencia_menos_frecuente = frecuencia),
    by = "modelo"
  ) %>%
  left_join(confusion_bajo_medio, by = "modelo") %>%
```

```
  left_join(confusion_alto_medio, by = "modelo") %>%
  left_join(errores_extremos, by = "modelo") %>%
  mutate(
    across(c(confusion_baja_media, confusion_alta_media, errores_graves), ~ replace_na(., 0))
  ) %>%
  arrange(desc(errores_graves), desc(frecuencia_mas_frecuente))

kable(
  resumen_patrones_error,
  caption = "Patrones criticos de error por modelo SVM"
)
```

Table 16: Patrones criticos de error por modelo SVM

| modelo | error_mas_frecuente | frecuencia_mas_frecuente | error_menos_frecuente | frecuencia_menos_frecuente | confusion_baja_media | confusion_alta_media | errores_graves |
|---|---|---|---|---|---|---|---|
| SVM radial | media -> cara | 2672 | cara -> barata | 171 | 1380 | 3360 | 2702 |
| SVM polinomial | cara -> media | 1336 | barata -> cara | 288 | 2544 | 2398 | 804 |
| SVM lineal | cara -> media | 1084 | barata -> cara | 155 | 1815 | 1950 | 455 |

### Implicaciones para la categorizacion de precios

```
clasificar_gravedad_error <- function(real, prediccion, nivel_bajo, nivel_alto) {
  case_when(
    real == prediccion ~ "Acierto",
    real == nivel_bajo & prediccion == nivel_alto ~ "Error grave",
    real == nivel_alto & prediccion == nivel_bajo ~ "Error grave",
    TRUE ~ "Error moderado"
  )
}

errores_svm_gravedad <- errores_svm %>%
  mutate(
    gravedad = clasificar_gravedad_error(real, prediccion, nivel_bajo, nivel_alto)
  )

resumen_gravedad <- errores_svm_gravedad %>%
  filter(tipo == "error") %>%
  group_by(modelo, gravedad) %>%
  summarise(total = sum(frecuencia), .groups = "drop") %>%
  arrange(modelo, desc(total))

kable(
  resumen_gravedad,
  caption = "DistribuciOn de errores moderados y graves en modelos SVM"
)
```

Table 17: DistribuciOn de errores moderados y graves en modelos SVM

| modelo | gravedad | total |
|---|---|---|
| SVM lineal | Error moderado | 3765 |
| SVM lineal | Error grave | 455 |
| SVM polinomial | Error moderado | 4942 |
| SVM polinomial | Error grave | 804 |
| SVM radial | Error moderado | 4740 |
| SVM radial | Error grave | 2702 |

La gravedad se define con prioridad para los errores entre extremos de precio. Si en una actualizacion del proyecto cambian los niveles de la variable objetivo, la logica se adapta usando el primer y ultimo nivel como extremos para conservar consistencia.

## Seleccion del clasificador SVM mas estable

```
resumen_final_svm <- resumen_svm %>%
  left_join(
    tabla_ajuste_svm %>% select(modelo, accuracy_train, accuracy_test, diferencia, diagnostico),
    by = "modelo"
  ) %>%
  arrange(desc(balanced_accuracy_promedio), desc(kappa), tiempo_segundos)

kable(
  resumen_final_svm,
  digits = 4,
  caption = "Criterio integrado para seleccionar el modelo SVM mas estable"
)
```

Table 18: Criterio integrado para seleccionar el modelo SVM mas estable

| modelo | accuracy | kappa | balanced_accuracy | sensibilidad_promedio | especificidad_promedio | tiempo_segundos | accuracy_test | accuracy_train | diferencia | diagnostico |
|---|---|---|---|---|---|---|---|---|---|---|
| SVM lineal | 0.8771 | 0.7366 | 0.8623 | 0.7945 | 0.9301 | NA | 0.8786 | 0.8771 | 0.0014 | Ajuste razonable |
| SVM polinomial | 0.8327 | 0.6431 | 0.8121 | 0.7185 | 0.9057 | NA | 0.8361 | 0.8327 | 0.0034 | Ajuste razonable |
| SVM radial | 0.7833 | 0.4448 | 0.6801 | 0.5563 | 0.8039 | NA | 0.7850 | 0.7833 | 0.0017 | Ajuste razonable |

```
mejor_svm <- resumen_final_svm %>%
  arrange(desc(balanced_accuracy_promedio), desc(kappa), tiempo_segundos) %>%
  slice(1)

mejor_svm
```

```
## # A tibble: 1 x 11
##   modelo     accuracy kappa balanced_accuracy_promedio sensibilidad_promedio
##   <chr>         <dbl> <dbl>                      <dbl>                 <dbl>
## 1 SVM lineal    0.877 0.737                      0.862                 0.794
## # i 6 more variables: especificidad_promedio <dbl>, tiempo_segundos <dbl>,
## #   accuracy_train <dbl>, accuracy_test <dbl>, diferencia <dbl>,
## #   diagnostico <chr>
```

La seleccion final integra desempeno global, desempeno por clase, eficiencia de entrenamiento y estabilidad de generalizacion (`accuracy_train` vs. `accuracy_test`). Este criterio reduce el riesgo de elegir un modelo rapido pero inestable, o uno preciso en promedio con errores criticos para negocio.

## Redaccion integrable al informe ejecutivo

Despues de evaluar individualmente los modelos SVM, se consolidaron sus resultados para comparar no solo la exactitud global, sino tambien la estabilidad del desempeno por categoria. Esta comparacion es relevante porque SmartStay Advisors no necesita unicamente un modelo que acierte con frecuencia, sino uno que clasifique de manera confiable las propiedades baratas, medias y caras, reduciendo errores que puedan afectar las recomendaciones comerciales.

El analisis de las matrices de confusion permitio identificar los patrones de error mas frecuentes. En este contexto, no todos los errores tienen la misma relevancia: confundir una propiedad media con una barata puede tener un efecto moderado, mientras que clasificar una propiedad cara como barata puede generar expectativas incorrectas en el cliente y afectar la rentabilidad esperada.

Al comparar los modelos SVM con los clasificadores desarrollados en entregas anteriores, se mantuvo el mismo conjunto de entrenamiento y prueba para asegurar una evaluacion justa. Bajo estas condiciones, el mejor modelo se selecciona con base en metricas complementarias como `accuracy`, `Kappa`, `balanced accuracy`, tiempo de procesamiento y estabilidad entre entrenamiento y prueba.

## Preparacion del problema de prediccion de precios

Ademas de clasificar las propiedades por categoria de precio, se construyeron modelos SVR para estimar directamente el valor monetario de los alojamientos. Este enfoque complementa el analisis de clasificacion al responder una pregunta distinta: no en que rango cae el precio, sino cual es el precio esperado. Mantener el mismo particionamiento experimental garantiza que la comparacion posterior con modelos de regresion de entregas anteriores sea valida.

```
## Train: 137400 filas | price presente: TRUE
```

```
## Test:  34348 filas | price presente: TRUE
```

## Transformacion de predictores para SVR

SVR es sensible a la escala de las variables, por lo que requiere el mismo proceso de limpieza, codificacion dummy y estandarizacion aplicado en la fase de clasificacion. Adicionalmente, se elimina `price_category` para evitar fuga de informacion, ya que esa variable fue derivada directamente del precio.

Table 19: Variables con mas faltantes en entrenamiento (SVR)

| variable | faltantes |
|---|---|
| calendar_updated | 60934 |
| neighbourhood_group_cleansed | 30531 |
| review_scores_accuracy | 10783 |
| review_scores_cleanliness | 10783 |
| review_scores_checkin | 10783 |
| review_scores_communication | 10783 |
| review_scores_location | 10783 |
| review_scores_value | 10783 |
| review_scores_rating | 10781 |
| reviews_per_month | 10781 |
| license | 8442 |
| host_listings_count | 509 |
| host_total_listings_count | 509 |
| bedrooms | 93 |
| beds | 67 |
| minimum_minimum_nights | 36 |
| maximum_minimum_nights | 36 |
| minimum_maximum_nights | 36 |
| maximum_maximum_nights | 36 |
| bathrooms | 11 |

Table 20: Variables con mas faltantes en prueba (SVR)

| variable | faltantes |
|---|---|
| calendar_updated | 15312 |
| neighbourhood_group_cleansed | 7590 |
| review_scores_accuracy | 2634 |
| review_scores_cleanliness | 2634 |
| review_scores_checkin | 2634 |
| review_scores_communication | 2634 |
| review_scores_location | 2634 |
| review_scores_value | 2634 |
| review_scores_rating | 2632 |
| reviews_per_month | 2632 |
| license | 2075 |
| host_listings_count | 118 |
| host_total_listings_count | 118 |
| bedrooms | 28 |
| beds | 13 |
| minimum_minimum_nights | 11 |
| maximum_minimum_nights | 11 |
| minimum_maximum_nights | 11 |
| maximum_maximum_nights | 11 |
| bathrooms | 3 |

```
## Dimensiones train_svr: 60934 x 307
```

```
## Dimensiones test_svr:  15312 x 307
```

```
## NA en train_svr: FALSE
```

```
## NA en test_svr:  FALSE
```

El RMSE penaliza con mayor peso los errores grandes, lo que resulta util cuando una prediccion muy alejada del precio real puede generar recomendaciones comerciales erroneas. El MAE complementa esta lectura al expresar el error promedio en unidades monetarias directamente interpretables. El $R^2$ indica que proporcion de la variabilidad del precio fue capturada por el modelo, facilitando la comparacion relativa entre kernels.

## Ajuste de modelos de regresion con vectores de soporte

Una vez transformados los datos para regresion, se entrenaron tres variantes de SVR con distinto tipo de kernel. El kernel lineal actua como referencia y es eficiente computacionalmente. El kernel radial captura relaciones no lineales suavizadas por el ancho de banda sigma. El kernel polinomial permite superficies de mayor curvatura segun el grado elegido. La validacion cruzada sobre cada grilla de hiperparametros permite seleccionar la configuracion con menor error de prediccion antes de evaluar en el conjunto de prueba.

### SVR con kernel lineal

```
## Support Vector Machines with Linear Kernel
##
## 3000 samples
##  306 predictor
##
## No pre-processing
## Resampling: None
```

El kernel lineal asume que la relacion entre los predictores y el precio es aproximadamente lineal en el espacio transformado. Su ventaja principal es la velocidad de ajuste y la facilidad de interpretacion del parametro C, que controla la tolerancia frente a errores dentro del margen epsilon.

### SVR con kernel radial

```
## Support Vector Machines with Radial Basis Function Kernel
##
## 3000 samples
##  306 predictor
##
## No pre-processing
## Resampling: None
```

El kernel radial introduce una funcion de base que mide similitud exponencial entre observaciones. El parametro sigma controla el alcance de esta influencia: valores pequenos hacen el modelo mas local y sensible a vecinos cercanos, mientras que valores grandes suavizan la superficie de prediccion. La combinacion con C determina la complejidad efectiva del modelo.

### SVR con kernel polinomial

```
## Support Vector Machines with Polynomial Kernel
##
```

```
## 3000 samples
##  306 predictor
##
## No pre-processing
## Resampling: None
```

El kernel polinomial de grado 2 genera superficies cuadraticas de prediccion, mientras que el de grado 3 agrega mayor curvatura. Grados elevados combinados con C alto aumentan el riesgo de sobreajuste, por lo que la validacion cruzada es esencial para identificar la configuracion que generaliza mejor al conjunto de prueba.

## Evaluacion del error predictivo

Con los tres modelos entrenados se generaron predicciones sobre el conjunto de prueba y se calcularon las metricas RMSE, MAE y $R^2$. La comparacion directa entre kernels revela cual configuracion logra el menor error y mayor capacidad explicativa sobre datos no vistos durante el entrenamiento.

Table 21: Metricas de regresion SVR sobre el conjunto de prueba

| modelo | RMSE | MAE | R2 | tiempo_segundos |
|---|---|---|---|---|
| SVR polinomial | 4091.276 | 567.8035 | 0.1105 | NA |
| SVR lineal | 4120.543 | 567.2165 | 0.2058 | NA |
| SVR radial | 4294.919 | 637.9637 | 0.0029 | NA |

```
## Mejor modelo SVR: SVR polinomial
```

```
## RMSE: 4091.276
```

```
## MAE:  567.8035
```

```
## R²:   0.1105
```

## Diagnostico visual de predicciones

Los graficos de valores reales contra predichos y de residuos permiten detectar patrones sistematicos de error que las metricas agregadas no capturan. Un buen modelo deberia mostrar puntos cercanos a la diagonal en el primer grafico y residuos distribuidos sin estructura en torno a cero en el segundo.

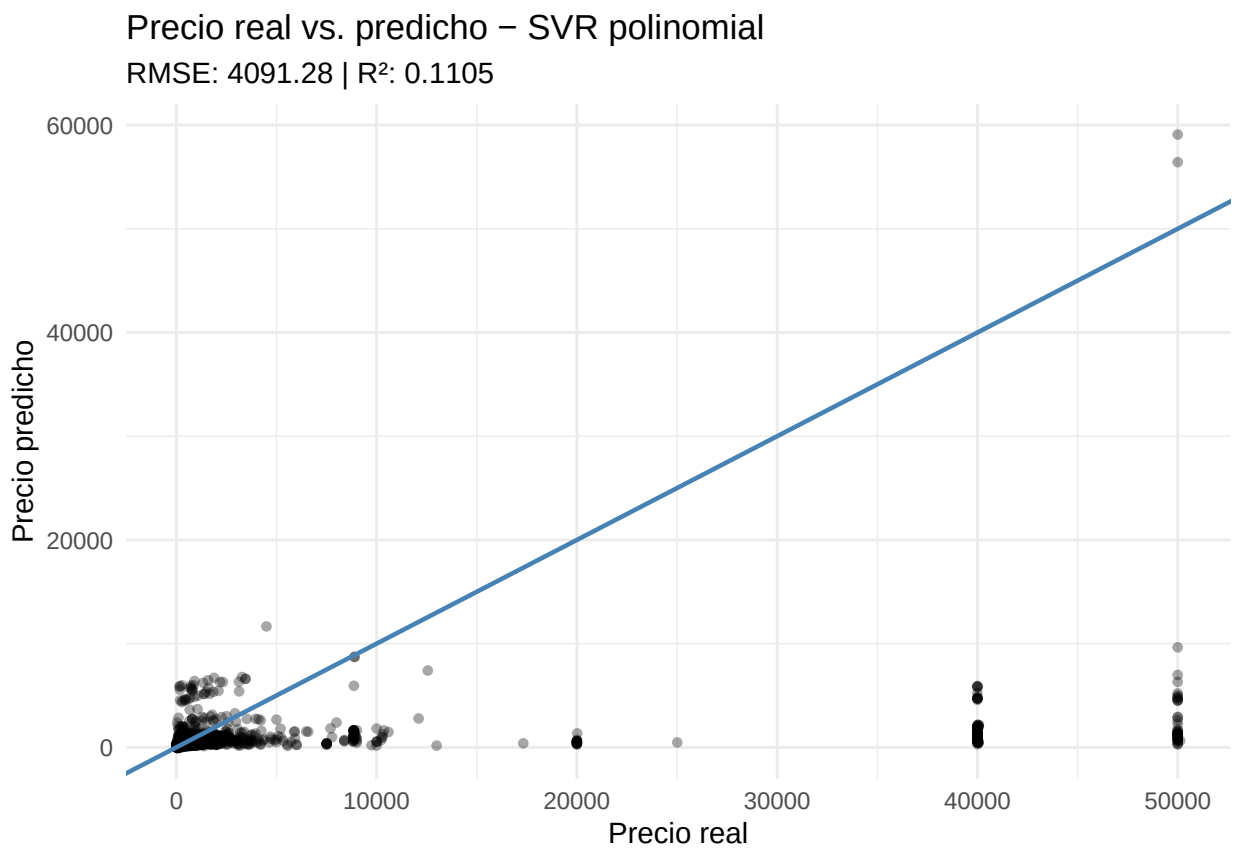
Precio real vs. predicho − SVR polinomial
RMSE: 4091.28 | R²: 0.1105
60000
40000
20000
0
Precio predicho
0
10000
20000
30000
40000
50000
Precio real

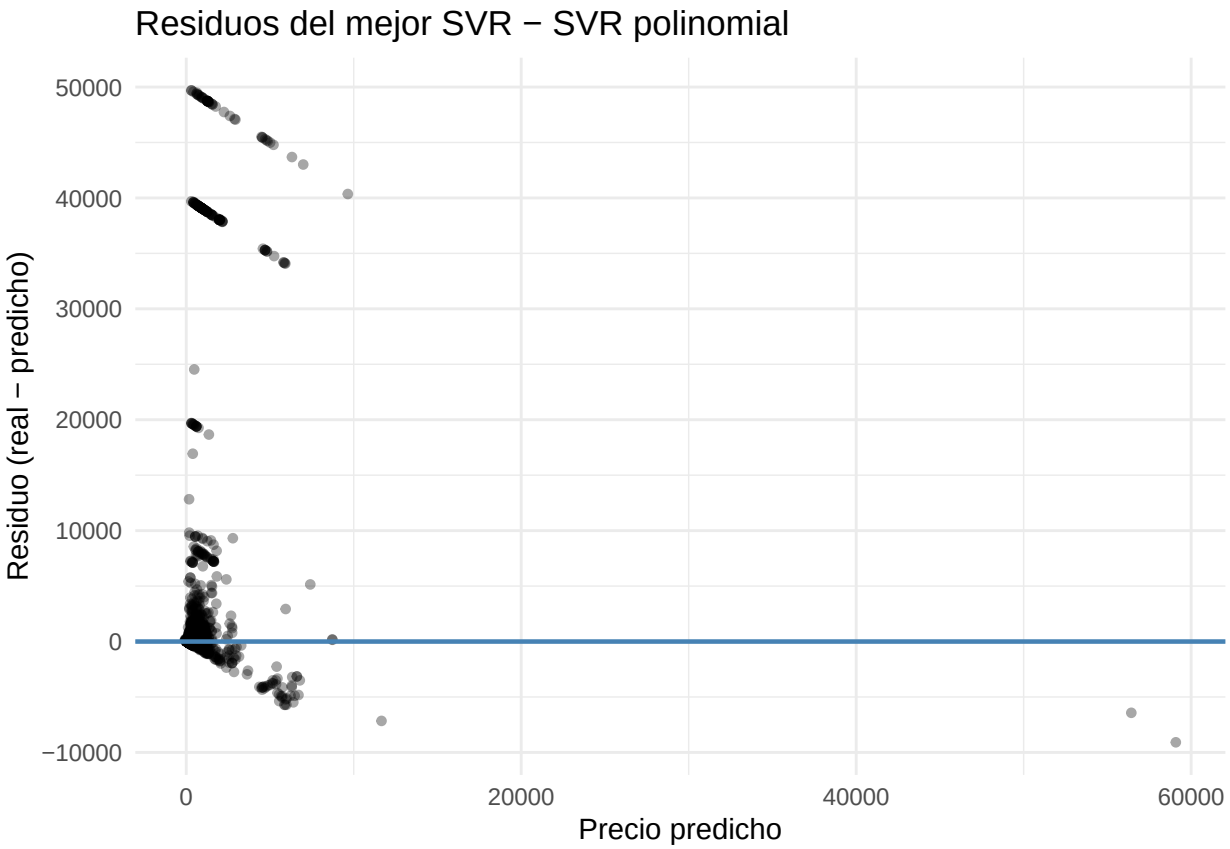


### Comparacion con modelos de regresion anteriores

La tabla siguiente consolida el desempeno de los tres kernels SVR sobre el conjunto de prueba, ordenados de menor a mayor RMSE, para identificar cual configuracion logra el mejor equilibrio entre error y capacidad explicativa.

Table 22: Comparacion de kernels SVR: desempeno sobre el conjunto de prueba

| modelo | RMSE | MAE | R2 | tiempo_segundos |
|---|---|---|---|---|
| SVR polinomial | 4091.276 | 567.8035 | 0.1105 | NA |
| SVR lineal | 4120.543 | 567.2165 | 0.2058 | NA |
| SVR radial | 4294.919 | 637.9637 | 0.0029 | NA |

Ademas de clasificar las propiedades por categoria de precio, se desarrollaron modelos SVR para estimar directamente el precio de los alojamientos. Este enfoque complementa el analisis de clasificacion al responder una pregunta distinta: no en que rango cae el precio, sino cual es el valor esperado. Para garantizar comparaciones validas, se mantuvo el mismo particionamiento experimental utilizado en entregas anteriores.

Los modelos fueron evaluados mediante RMSE, MAE y $R^2$. El RMSE penaliza con mayor fuerza los errores grandes, el MAE expresa el error promedio en unidades monetarias directamente interpretables y el $R^2$ indica que proporcion de la variabilidad del precio fue capturada por el modelo. La seleccion del mejor SVR considero estas tres metricas de forma conjunta junto con el tiempo de procesamiento requerido.